ឯកសារតេស្តសមត្ថភាព OCR និង PyMuPDF

Khmer Language Processing, Text Extraction & OCR Evaluation Suite

គោលបំណងនៃឯកសារ (Document Purpose)

ឯកសារនេះត្រូវបានរៀបចំឡើងដើម្បីធ្វើតេស្តការស្រង់អត្ថបទ (Text Extraction) ដោយប្រើប្រាស់បណ្ណាល័យ **PyMuPDF (FitZ)** និងការស្គាល់អក្សររូបភាព **OCR (Optical Character Recognition)** សម្រាប់ភាសាខ្មែរ។ វាផ្ទុកទៅដោយព្យញ្ជនៈ ស្រៈ ជើងអក្សរ លេខខ្មែរ និងទម្រង់តារាងផ្សេងៗ។

១. ការតេស្តទម្រង់អក្សរខ្មែរ (Khmer Typography & Structure Test)

ការប្រៀបធៀបលេខ (Numerals)

លេខខ្មែរ: ០ ១ ២ ៣ ៤ ៥ ៦ ៧ ៨ ៩

លេខសកល: 0 1 2 3 4 5 6 7 8 9

កាលបរិច្ឆេទតេស្ត៖ ថ្ងៃទី ២២ ខែតុលា ឆ្នាំ ២០២៦

សញ្ញាពិសេស (Punctuation)

សញ្ញាខណ្ឌ: ៕ (Khmer Khan)

សញ្ញាល៉ៈក: ៖ (Khmer Camnuc Pi Kbal)

សញ្ញាបារាំង: « » (Guillemets)

២. តារាងទិន្នន័យគំរូ (Sample Data Table for Extraction)

ល.រ	ឈ្មោះសមាសភាគ	ប្រភេទតេស្ត	បរិមាណ	ស្ថានភាព
០១	ការស្រង់អត្ថបទដើម (Direct Text)	PyMuPDF Parsing	១០០%	ជោគជ័យ
០២	ការស្គាល់អក្សរភាព (Image OCR)	Tesseract / Vision	៩៥%	កំពុងតេស្ត
០៣	ការបំបែកពាក្យ (Word Segmentation)	NLP Dictionary	៥០ កថាខណ្ឌ	រង់ចាំ
០៤	ជើងអក្សរនិងស្រៈតម្រួត (Subscripts)	Font Rendering	គ្រប់តួ	ជោគជ័យ

៣. អត្ថបទស្មុគស្មាញ និងកថាខណ្ឌគំរូ (Complex Text Paragraphs)

ព្រះរាជាណាចក្រកម្ពុជា ជាប្រទេសមួយស្ថិតនៅក្នុងតំបន់អាស៊ីអាគ្នេយ៍។ ភាសាផ្លូវការគឺភាសាខ្មែរ ដែលជាភាសាមួយមានប្រវត្តិសាស្ត្រវែងឆ្ងាយ និងមានប្រព័ន្ធសំណេរផ្ទាល់ខ្លួនយ៉ាងសម្បូរបែប។ ការអភិវឌ្ឍប្រព័ន្ធ OCR សម្រាប់ភាសាខ្មែរតម្រូវឱ្យមានការយល់ដឹងស៊ីជម្រៅអំពីការតម្រៀបស្រៈ ជើងអក្សរ និងការបំបែកពាក្យ (Tokenization) ព្រោះភាសាខ្មែរមិនប្រើប្រាស់ចន្លោះ (Space) ដើម្បីបំបែករវាងពាក្យនិងពាក្យនោះទេ។

៤. សាកល្បងជើងអក្សរ និងស្រៈទាំងអស់ (Khmer Consonants & Subscripts)

ព្យញ្ជនៈ ៣៣ តួ: ក ខ គ ឃ ង ច ឆ ជ ឈ ញ ដ ឋ ឌ ឍ ណ ត ថ ទ ធ ន ប ផ ព ភ ម យ រ ល វ ស ហ ឡ អ

ជើងអក្សរគំរូ: ◌្ក ◌្ខ ◌្គ ◌្ឃ ◌្ង ◌្ច ◌្ឆ ◌្ជ ◌្ឈ ◌្ញ ◌្ដ ◌្ឋ ◌្ឌ ◌្ឍ ◌្ណ ◌្ត ◌្ថ ◌្ទ ◌្ធ ◌្ន ◌្ប ◌្ផ ◌្ព ◌្ភ ◌្ម ◌្យ ◌្រ ◌្ល ◌្វ ◌្ស ◌្ហ ◌្ឡ ◌្អ

ពាក្យពិបាកតេស្ត OCR: ស្ត្រី, ផ្កាយ, ផ្លូវ, ត្រី, ស្ម័គ្រចិត្ត, អភិវឌ្ឍន៍, ប្រជាធិបតេយ្យ, ព្រះហស្ត

៥. កូដគំរូសម្រាប់តេស្ត PyMuPDF (Sample Python Script)

```
      import fitz # PyMuPDF doc = fitz.open("khmer_ocr_pymupdf_test.pdf") for page_num
in range(len(doc)): page = doc[page_num] text = page.get_text("text") print(f"--- Page
{page_num + 1} ---") print(text)
```

៦. ការកំណត់សម្គាល់សម្រាប់វិស្វករ (Engineer Notes)

នៅពេលប្រើប្រាស់ PyMuPDF ដើម្បីទាញយកអត្ថបទខ្មែរ ប្រសិនបើពុម្ពអក្សរ (Font) នៅក្នុង PDF មិនបានបង្កប់ (Embed) Unicode ToUnicode Map ឱ្យបានត្រឹមត្រូវទេ នោះលទ្ធផលអត្ថបទដែលទាញបានអាចជាអក្សរប្រឡាក់ ឬសញ្ញាសួរ (?)។ ក្នុងករណីនោះ ការប្រើប្រាស់ OCR លើរូបភាពទំព័រ (Rasterized Page Image) គឺជាដំណោះស្រាយជំនួស។