សុំនុំឯកសារតេស្តសមត្ថភាពអាន និងស្រង់អត្ថបទភាសាខ្មែរ

ស្តង់ដារវាយតម្លៃការបំបែកទិន្នន័យ ឯកសារ ភីឌីអេហ្វ និងការស្គាល់អក្សររូបភាព

គោលបំណងនៃឯកសារ

ឯកសារតេស្តនេះត្រូវបានរៀបចំឡើងជាភាសាខ្មែរទាំងស្រុង ដើម្បីធ្វើការវាយតម្លៃលើប្រព័ន្ធបំបែកទិន្នន័យអត្ថបទ **ភីយូអឹមភីឌីអេហ្វ (PyMuPDF)** និងប្រព័ន្ធស្គាល់អក្សររូបភាព **អូស៊ីអរ (OCR)**។ វាជួយពិនិត្យមើលភាពត្រឹមត្រូវនៃការអានកថាខណ្ឌ តារាង ជើងអក្សរ ស្រៈតម្រួត និងលេខខ្មែរ។

១. ការផ្ទៀងផ្ទាត់តួអក្សរ និងសញ្ញាវណ្ណយុត្តិខ្មែរ

លេខ និងកាលបរិច្ឆេទ

លេខខ្មែរ៖ ០ ១ ២ ៣ ៤ ៥ ៦ ៧ ៨ ៩

កាលបរិច្ឆេទ៖ ថ្ងៃទី ២២ ខែតុលា ឆ្នាំ ២០២៦

រង្វាស់រង្វាល់៖ ១០០ ភាគរយ, ៥០ គីឡូម៉ែត្រ

សញ្ញានិងស្ថានភាពតេស្ត

សញ្ញាខណ្ឌ៖ ៕ (សញ្ញាបញ្ចប់កថាខណ្ឌ)

សញ្ញាល៉ែក៖ ៖ (សញ្ញាចំណុចពីរគូ)

ស្ថានភាព៖ កំពុងដំណើរការ ជោគជ័យ

២. តារាងវាយតម្លៃសមត្ថភាពការស្រង់ទិន្នន័យ

ល.រ	ឧបករណ៍តេស្ត	ទម្រង់ទិន្នន័យគោលដៅ	កម្រិតប្រាកដ	លទ្ធផលតេស្ត
០១	ការស្រង់អក្សរដោយផ្ទាល់	ទិន្នន័យអត្ថបទយូនីកូដ	៩៩.៨%	ជោគជ័យ
០២	ការអានរូបភាពអត្ថបទ	រូបភាពកម្រិត ៣០០ ឌីភីអាយ	៩៦.៥%	កំពុងពិនិត្យ
០៣	ការស្វែងរកព្រំដែនតារាង	ក្រឡានិងជួរដេកតារាង	១០០.០%	ជោគជ័យ
០៤	ការកំណត់ប្រអប់អត្ថបទ	កូអរដោនេផ្ទៃទំព័រ	៩៨.២%	ជោគជ័យ

៣. បញ្ហាប្រឈមក្នុងការបំបែកអត្ថបទខ្មែរ

ការវិភាគទម្រង់ឯកសារភាសាខ្មែរជួបប្រទះការលំបាកដោយសារតែភាសាខ្មែរមិនប្រើប្រាស់ចន្លោះមិនឃើញ (Space) ដើម្បីបំបែករវាងពាក្យនិងពាក្យនោះទេ។ ប្រព័ន្ធកុំព្យូទ័រត្រូវប្រើប្រាស់ក្បួនបំបែកពាក្យផ្អែកលើវចនានុក្រម ដើម្បីធានាថាការស្រង់ចេញនូវកថាខណ្ឌ ជួរឈរ និងអត្ថបទតាមលំដាប់លំដោយត្រឹមត្រូវ ដោយមិនមានការរំលង ឬកាត់ផ្តាច់ជើងអក្សរឡើយ។

៤. សំណុំតួអក្សរ និងជើងអក្សរពិសេស

តួអក្សរតម្រួត៖ ស្ត្រី, ផ្កាយ, ផ្លូវ, ត្រី, ស្ម័គ្រចិត្ត, អភិវឌ្ឍន៍, ប្រជាធិបតេយ្យ, ព្រះហស្ត, វិទ្យាសាស្ត្រ, សុខាភិបាល។

ព្យញ្ជនៈធ្សាំ៖ ហ្គ, ហ្ន, ហ្ម, ហ្ល, ហ្វ, ហ្ស, ហ្ស៊ូ។

ស្រៈនិស្ស័យ៖ ◌ា ◌ិ ◌ី ◌ឹ ◌ឺ ◌ុ ◌ូ ◌ួ ◌ើ ◌ឿ ◌ៀ ◌េ ◌ែ ◌ៃ ◌ោ ◌ៅ ◌ុំ ◌ំ ◌ះ ◌ុះ ◌េះ ◌ោះ។

៥. ជំហានការងារស្ម័យប្រវត្តិកម្ម

១. បើកឯកសារ ភីឌីអេហ្វ (PDF) តាមរយៈបណ្ណាល័យកម្មវិធី ២. អានចំនួនទំព័រ និងទាញយកទិន្នន័យអត្ថបទតាមប្រអប់នីមួយៗ ៣. ពិនិត្យមើលកូដយូនីកូដ និងជើងអក្សរខ្មែរ ៤. បើការស្រង់អត្ថបទមិនបានជោគជ័យ ត្រូវប្តូរទៅប្រើប្រាស់ប្រព័ន្ធ អូស៊ីអរ (OCR) ៥. រក្សាទុកលទ្ធផលជាទម្រង់ទិន្នន័យរៀបរយ

៦. កំណត់សម្គាល់បច្ចេកទេសសម្រាប់វិស្វករ

ក្នុងករណីដែលឯកសារ ភីឌីអេហ្វ មិនបានបង្កប់ពុម្ពអក្សរយូនីកូដខ្មែរឱ្យបានត្រឹមត្រូវទេ នោះប្រព័ន្ធស្រង់អត្ថបទដោយផ្ទាល់នឹងទទួលបានអក្សរដែលអានមិនយល់។ ក្នុងស្ថានភាពបែបនេះ វិស្វករត្រូវកំណត់ប្រព័ន្ធឱ្យបង្វែរទំព័រឯកសារទៅជារូបភាពដែលមានកម្រិតច្បាស់ខ្ពស់ រួចបញ្ជូនទៅកាន់ប្រព័ន្ធ អូស៊ីអរ (OCR) ដើម្បីអានអក្សរពីរូបភាពឡើងវិញ។